

Gdje nastaje stilski rizik hijerarhijske alokacije?

Kontrolirana studija prostora hijerarhije i overlay ograničenja faktorskih beta na indeksu S&P 500 (2013.--2025.)

Marin Meštrović

Dubinska analiza podataka i otkrivanje znanja iz podataka
PMF, Sveučilište u Zagrebu

Lipanj 2026.

Sažetak

Hijerarhijski alokatori (HRP, HERC, NCO) obećavaju diverzifikaciju bez procjene očekivanih prinosa, ali nasljeđuju inverzno-varijančni mehanizam minimalne varijance. Pitamo *gdje* u cjevovodu nastaje stilski rizik: u prostoru u kojem se hijerarhija gradi (korelacijskom naspram faktorskom) ili u mehanizmu alokacije i ograničenja. Na point-in-time univerzumu S&P 500 (2013.--2025., 13 prozora), držeći metodu veze konstantnom (Wardova veza u oba kraka), manipuliramo isključivo ulazom u hijerarhiju i dodajemo projekcijski QP overlay $|w^\top \beta_f| \leq \varepsilon$ na hijerarhijske težine $\rightarrow$ potpuni 2×2 faktorijal $\{\text{prostor}\} \times \{\text{bez/sa ograničenjem}\}$. Nalazi: **(H1)** NCO u cijelosti nasljeđuje RMW/CMA nagib (koncentracija stila $0.80 \approx \text{min-var } 0.78 \gg 1/N \text{ } 0.59$); HRP i HERC nasljeđuju *mehanizam* (težina raste s padom rezidualne volatilnosti i porastom CMA-izloženosti), ali ga raspršuju na razinu $1/N$. **(H2)** faktorski prostor *ne* neutralizira nagib (razlika obuhvaća nulu), a očekivani dobitak u stabilnosti klastera ne ostvaruje se pri $K = 10$ – jedina mu je konkretna prednost parsimonija ($\sim 34\times$ manje parametara). **(H3)** jedini mehanizam koji nagib uklanja jest izravno linearno ograničenje na bete; primijenjen kao overlay, značajno smanjuje koncentraciju stila (5/6 varijanti) uz zanemariv trošak u volatilnosti i dominira na granici stil--volatilnost. Stari projekt (dijagnoza min-vara i izravna neutralnost) ugnježđuje se kao referentna obitelj.

Sadržaj

Uvod i hipoteze	3
Podaci	4
Metodologija	4
Faza 1: Replikacija u korelacijskom prostoru	6
Faza 2: Dijagnoza — nasljeđuju li alokatori nagib? (H1)	6
Faza 3: Prostor hijerarhije — neutralizira li faktorski prostor nagib? (H2)	9
Faza 4: Mehanizam i lijek — overlay ograničenje beta (H3)	9
Stari projekt kao referenca i motivacija	11
Zaključak	11
Literatura	12

Uvod i hipoteze

Portfelji minimalne varijance s dugim pozicijama uobičajeno se promatraju kao neutralna referenca, no poznato je da nose sustavnu izloženost faktorima: optimizacija koja minimizira varijancu favorizira niskovolatilne dionice, a te su dionice ujedno sklone profilu visoke profitabilnosti i niskoga ulaganja (Scherer, 2011; Novy-Marx, 2014). Prethodna faza ovog projekta pokazala je upravo to na min-var portfelju te utvrdila da grupna ograničenja po klasteru ne uklanjaju nagib, dok ga izravno linearno ograničenje na faktorske bete uklanja.

Moderni *hijerarhijski* alokatori — Hierarchical Risk Parity (HRP; López de Prado, 2016), Hierarchical Equal Risk Contribution (HERC; Raffinot, 2018) i Nested Clustered Optimization (NCO; López de Prado, 2019) — predstavljaju se kao robusnija alternativa: izbjegavaju invertiranje loše uvjetovane kovarijance tako što kapital raspoređuju niz dendrogram dobiven klasteriranjem. Pritom dijele istu inverzno-varijantnu jezgru kao minimalna varijanca. Otvoreno je pitanje **gdje u njihovu cjevovodu nastaje stilski rizik**: u *prostoru* u kojem se hijerarhija gradi ili u *mehanizmu* alokacije i ograničenja.

Dizajn kontrolirane studije. Jedina manipulirana varijabla jest ulaz u izgradnju hijerarhije: *korelacijsko* stablo naspram *Wardova* stabla na standardiziranim petfaktorskim značajkama. Da usporedba prostora ne konfundira metodu veze, kontrolirana usporedba drži vezu konstantnom — **Wardova veza u oba kraka** (`hrp_corr_ward` naspram `hrp_factor`); jednostruka veza vjerna izvorniku (`hrp_corr_single`) zadržava se isključivo kao replikacijski red. Sve ostalo je identično: point-in-time S&P 500, isti prozori, ista Ledoit--Wolfova kovarijanca, isti $w_{\max}$, iste metrike. U završnoj fazi dodaje se projekcijski QP overlay $|w^\top \beta_f| \leq \varepsilon$ na hijerarhijske težine, čime nastaje potpuni 2×2 faktorijal $\{\text{prostor hijerarhije}\} \times \{\text{bez/sa ograničenjem}\}$.

Hipoteze (postavljene unaprijed). Primarni ishod je *koncentracija stila* $|\beta_{\text{SMB}}| + |\beta_{\text{HML}}| + |\beta_{\text{RMW}}| + |\beta_{\text{CMA}}|$ iz petfaktorske atribucije ostvarenih testnih prinosa.

- **H1.** Korelacijski HRP/HERC/NCO nasljeđuju skriveni RMW/CMA nagib minimalne varijance (mehanizam: inverzno-varijantna alokacija favorizira niskovolatilne grane; Scherer, 2011; Novy-Marx, 2014). *Testira se u Fazi 2.*
- **H2.** Ni faktorski prostor hijerarhije ne neutralizira nagib (lekcija da upravljanje težinama skupina ne cilja pojedinačnu betu), ali donosi mjerljive dobitke u stabilnosti klastera, obrtaju i interpretabilnosti (redukcija dimenzije: $\sim N^2/2$ korelacija naspram $6N$ beta). *Testira se u Fazi 3.*
- **H3.** Jedini mehanizam koji nagib stvarno uklanja jest izravno linearno ograničenje na bete; primijenjeno kao overlay na hijerarhijske težine, dominira na granici koncentracija stila $\times$ ostvarena volatilitnost. *Testira se u Fazi 4.*

Mjesto u literaturi. HRP (López de Prado, 2016) gradi težine kvazidijagonalizacijom korelacijske matrice i rekurzivnom bisekcijom; NCO (López de Prado, 2019) ugnježđuje min-var unutar i među klasterima; HERC (Raffinot, 2018) dijeli kapital niz dendrogram po jednakom doprinosu riziku. Kovarijancu procjenjujemo Ledoit--Wolfvim sažimanjem (Ledoit & Wolf, 2004), a faktorsku strukturu petfaktorskim modelom (Fama & French, 2015). Za statističku inferenciju koristimo blok-bootstrap, Model Confidence Set (Hansen, Lunde & Nason, 2011) i Deflated Sharpe Ratio (Bailey & López de Prado, 2014). Doprinos rada nije nov alokator, nego *kontrolirana dekompozicija* koja izolira gdje nastaje stilski rizik i koji ga mehanizam uklanja.

Podaci


- **Skup dionica.** Point-in-time sastav indeksa S&P 500. Panel se gradi preko unije svih tickera koji su ikad članovi u razdoblju 2000.--2025., a po prozoru se reže na članstvo na datum kraja treniranja. Članstvo se rekonstruira iz javnog izvora (`fja05680/sp500`); spot-provjere poznatih indeksnih događaja (TSLA ulazi 2020-12, GM izlazi 2009-06, LEH izlazi 2008-09) prolaze.
- **Cijene.** Mjesečni prinosi iz prilagođenih zaključnih cijena (Yahoo Finance `yfinance`, sekundarno Stooq), sanirani na fizički moguć pojas $[-90\%, +300\%]$.
- **Faktori.** Fama--Frenchovi petfaktorski mjesečni prinosi (Ken French): MKT, SMB, HML, RMW, CMA.
- **Razdoblje backtesta.** Iako se podaci preuzimaju od 2000., klizni hod počinje od 2008-01, pa je prva testna godina **2013.**, a zadnja **2025.** (13 prozora, 156 testnih mjeseci).

Pokrivenost kao izmjerena veličina. Pristranost preživljavanja u point-in-time okviru manifestira se kao *nedostajući članovi*: jezgra od 321 delistanog imena iz pre-2010 razdoblja nema Yahoo povijest, no ta imena nisu članovi u zadržanim prozorima pa ih point-in-time presjek korektno izostavlja. Mjerimo udio članova s ≥ 60 valjanih mjeseci treniranja: raste s 54.75 % (prozor 2004-12) na 95.63 % (2024-12) (tablica 1, slika 1). Upravo zbog niske rane pokrivenosti backtest je podrezan na 2013.--2025., gdje je univerzum konzistentan (N po prozoru 347–481, prosjek ~ 411).

Tablica 1: Pokrivenost po odabranim prozorima procjene (cijeli dokument ima 21 redak).

Kraj treniranja	članova	s cijenama	s ≥ 60 mj.	% ≥ 60 mj.
2004-12	495	284	271	54.75
2009-12	499	339	322	64.53
2012-12	497	362	349	70.22
2016-12	506	411	390	77.08
2020-12	505	451	439	86.93
2024-12	503	491	481	95.63

Izvor: `outputs/tables/00_membership_coverage.csv`



Slika 1: Pokrivenost univerzuma kroz klizne prozore: broj članova, broj s valjanim cijenama i broj koji prolazi filter ≥ 60 mjeseci treniranja.

Metodologija

Značajke i klasteriranje. Za svaki par (prozor, dionica) procjenjujemo OLS petfaktorsku regresiju na viškovima prinosa iz trailing 60 mjeseci i bilježimo α , pet faktorskih beta, rezidualnu

volatilnost σ_ε i R^2 ; prilagodbe izvan granica kvalitete ($|\beta| \leq 5$, $\sigma_\varepsilon \leq 0.50$, $R^2 \geq 0.05$) izbacuju se iz tog prozora. *Faktorsko* stablo gradi se Wardovom vezom na šest standardiziranih značajki

$$(\beta_{\text{MKT}}, \beta_{\text{SMB}}, \beta_{\text{HML}}, \beta_{\text{RMW}}, \beta_{\text{CMA}}, \sigma_\varepsilon),$$

a *korelacijsko* stablo na udaljenosti $d = \sqrt{\frac{1}{2}(1 - \rho)}$ jednostrukom vezom (vjerni izvorNIK) odnosno Wardovom vezom (nositelj kontrolirane usporedbe).

Odabir broja klastera. HRP je K -neovisan (cijelo stablo rekurzivnom bisekcijom); K ulazi samo u HERC i NCO. Silueta u faktorskom prostoru monotono *pada* s K (tablica 2), pa $\arg\max$ trivijalno vraća najmanji K (rubni artefakt; struktura u faktorskom prostoru je slaba). K se zato bira *domenski*: pri ~ 400 imena $K = 10$ daje klastere ~ 40 imena, dovoljno da hijerarhija ugrize i da unutar-klasterski min-var bude stabilan. $K \in \{2, 3, 20\}$ i k-means drže se kao osjetljivost.

Tablica 2: Prosječna silueta po K u faktorskom prostoru (13 prozora). Nema unutarnjeg optimuma; pad je monoton, $K = 2$ je rubni artefakt.

K	2	3	4	5	7	10	12
silueta	0.349	0.185	0.166	0.148	0.127	0.118	0.119

Izvor: outputs/tables/02_silhouette_by_k.csv

Alokatori. Svi alokatori dijele isti post-korak $w_{\max}$ (iterativno odsijecanje na $w_{\max} = 0.05$ s renormalizacijom; uz težine se vraća `capped_weight_share`). Rizik je *wijek* iz prosljeđene Ledoit–Wolfve Σ (računa se jednom po prozoru i dijeli među alokatorima); **bete služe isključivo za izgradnju hijerarhije, nikad za procjenu rizika**. NCO particija = rez hijerarhijskog stabla na K u oba kraka (umjesto k-meansa iz izvornog rada). Vlastite implementacije validirane su na sintetičkom primjeru naspram referentnih biblioteka (tablica 3): HRP se podudara s `riskfolio-lib` na razini strojne preciznosti, NCO do tolerancije QP rješavača; preostale razlike su dokumentirane metodološke varijante, ne greške.

Tablica 3: Validacija vlastitih alokatora naspram biblioteka (sintetički primjer, 15 imovina).

Metoda	Biblioteka	$\max \Delta w $	Izvor razlike
HRP (single)	riskfolio-lib	2.8×10^{-17}	identičan algoritam ($\leq 10^{-6}$)
NCO (ward)	riskfolio-lib	2.3×10^{-5}	tolerancija QP rješavača
HERC (ward)	skfolio	3.7×10^{-2}	pravilo alokacije (Raffinot vs ERC)
HRP (single)	skfolio	1.3×10^{-1}	bisekcija po dendrogramu vs seriiranom poretku

Izvor: outputs/tables/09_validation_vs_libraries.csv

Overlay QP (Faza 4). Na hijerarhijske težine w_0 primjenjujemo projekciju

$$\min_w (w - w_0)^\top \Sigma (w - w_0) \text{ uz } \mathbf{1}^\top w = 1, 0 \leq w \leq w_{\max}, |w^\top \beta_f| \leq \varepsilon \forall f \in \{\text{SMB, HML, RMW, CMA}\},$$

za $\varepsilon \in \{0, 0.05, 0.10, 0.15\}$ (norma Σ primarno = minimalni tracking error; euklidska kao robustnost). Bete su iz istog prozora procjene (bez gledanja unaprijed). Tri alokatora $\times$ dva prostora $\times$ četiri $\varepsilon = 24$ overlay varijante.

Troškovi i statistika. Težine su fiksne unutar testne godine; trošak se obračunava samo na refit obrtaj $0.5 \sum_i |w_{i,t} - w_{i,t-1}|$ uz $t_c = 10$ bps na prvi mjesec godine. Za intervale razlika koristimo blok-bootstrap (pomični blokovi 12 mj., 1000 uzoraka, parne razlike sa zajedničkim uzorkovanjem). **Podjela posla:** Model Confidence Set (Hansen, Lunde & Nason, 2011) odgovara na pitanje *najmanje ostvarene varijance*, a Deflated Sharpe Ratio (Bailey & López de Prado, 2014) na *riziku prilagođeni prinosi* nakon korekcije za višestruko isprobavanje.

Faza 1: Replikacija u korelacijskom prostoru

Sva tri alokatora integrirana su u isti klizni walk-forward kao postojeći benchmarki, uz dijeljenu Σ po prozoru. Replikacijska tablica (tablica 4) pokazuje da su sve varijante izvedive u svih 13 prozora i da im se rizik kreće u uskom rasponu: ovo je jedna klasa imovine (US large-cap), pa prinosi ostaju ~ 0.97 korelirani neovisno o alokatoru — snaga studije dolazi iz *dispergije koncentracije stila*, ne iz dekorelacije prinosa.


Tablica 4: Replikacijska tablica: ostvarena godišnja volatilitnost, Sharpe (bruto i neto na 10 bps), maksimalni drawdown i prosječni jednostrani obrtaj (156 mjeseci).

Portfelj	god. vol.	Sharpe (br.)	Sharpe (neto)	maks. DD	obrtaj
jednake težine $1/N$	15.6 %	0.78	0.78	−26.8 %	0.12
minimalna varijanca	12.7 %	0.73	0.72	−19.0 %	0.52
faktorski neutralan $\varepsilon=0$	13.1 %	0.79	0.79	−19.2 %	0.56
hrp_corr_single ^a	13.6 %	0.83	0.83	−22.4 %	0.25
hrp_corr_ward	13.5 %	0.82	0.82	−22.9 %	0.25
herc_corr	14.3 %	0.74	0.73	−24.9 %	0.60
nco_corr ^b	12.3 %	0.80	0.80	−19.1 %	0.56

^a vjerna replikacija izvornika (López de Prado, 2016; jednostruka veza), isključivo replikacijski red — kontrolirana usporedba ide preko `hrp_corr_ward`. ^b NCO particija = rez stabla na K umjesto k-meansa iz izvornog rada.

Izvor: `outputs/tables/09_replication_summary.csv`

NCO ostvaruje najnižu volatilitnost (12.3 %), HRP najviši Sharpe (0.83); kumulativni rast prikazan je na slici 2. Pri $w_{\max} = 0.05$ cap pritišće zanemarivo (udio na capu 0.07 kod `nco_corr`, 0 kod ostalih hijerarhijskih), pa je mehanizam alokatora vidljiv, a ne artefakt ograničenja.



Slika 2: Kumulativni rast replikacijskih portfelja kroz testno razdoblje (2013.--2025.).

Faza 2: Dijagnoza — nasljeđuju li alokatori nagib? (H1)

Petfaktorska atribucija ostvarenih prinosa na punom testnom uzorku (tablica 5) otkriva jasnu raspodjelu koncentracije stila. Minimalna varijanca naginje profitabilnosti i niskom ulaganju ($\beta_{\text{RMW}} = 0.28$, $\beta_{\text{CMA}} = 0.39$; koncentracija stila 0.78), znatno iznad $1/N$ (0.59). **NCO u cijelosti nasljeđuje taj nagib** ($\beta_{\text{RMW}} = 0.32$, $\beta_{\text{CMA}} = 0.37$; koncentracija $0.80 \approx \text{min-var}$), dok HRP i HERC sliježu na razinu $1/N$ (0.55–0.57), *ispod* minimalne varijance.

Tablica 5: Petfaktorska atribucija na punom uzorku (156 mjeseci) i koncentracija stila s 95 % blok-bootstrap intervalom.

Portfelj	β_{MKT}	β_{SMB}	β_{HML}	β_{RMW}	β_{CMA}	konc. stila	95 % CI
jednake težine $1/N$	0.98	0.17	+0.18	0.17	0.07	0.59	[0.45, 0.72]
minimalna varijanca	0.73	0.04	-0.07	+0.28	+0.39	0.78	[0.49, 1.34]
hrp_corr_single	0.86	0.08	+0.05	+0.24	+0.18	0.55	[0.38, 0.83]
hrp_corr_ward	0.85	0.06	+0.08	+0.25	+0.18	0.57	[0.41, 0.81]
herc_corr	0.78	0.01	+0.07	+0.23	+0.25	0.57	[0.41, 1.21]
nco_corr	0.72	-0.07	-0.04	+0.32	+0.37	0.80	[0.63, 1.28]

Izvor: outputs/tables/10_attribution_full_sample.csv, 10_hidden_style_exposures.csv

Parne blok-bootstrap razlike (tablica 6) kvantificiraju nalaz: **nco_corr** se ne razlikuje od minimalne varijance po koncentraciji stila ($\Delta = +0.02$, $p = 0.64$), ali je značajno iznad $1/N$ ($\Delta = +0.20$, $p = 0.038$). HRP i HERC su *ispod* minimalne varijance, no razlika je granična (**hrp_corr_single** $\Delta = -0.23$, $p = 0.052$).

Tablica 6: Blok-bootstrap razlike koncentracije stila (zajedničko uzorkovanje, 1000 uzoraka).

Portfelj	u odnosu na	Δ konc. stila	95 % CI	p
hrp_corr_single	min-var	-0.227	[-0.59, 0.00]	0.052
hrp_corr_ward	min-var	-0.208	[-0.60, 0.02]	0.086
herc_corr	min-var	-0.202	[-0.47, 0.23]	0.520
nco_corr	min-var	+0.022	[-0.15, 0.21]	0.640
nco_corr	$1/N$	+0.203	[0.01, 0.70]	0.038

Izvor: outputs/tables/10_paired_diffs_vs_minvar.csv


Mehanizam. Iako HRP/HERC ne dosežu punu koncentraciju min-vara, *mehanizam* je prisutan u sva tri (tablica 7, slika 3): unutar prozora težina sustavno raste s padom rezidualne volatilnosti (korelacija -0.44 za **hrp_corr_ward**, -0.14 za **nco_corr**, naspram tek -0.04 za min-var) i s porastom CMA-izloženosti (+0.33 za **hrp_corr_ward**). Inverzno-varijanci jezgra upravo je kanal kroz koji se RMW/CMA nagib uvlači. **Zaključak H1: potvrđena za NCO, djelomično (mehanizam, ne puna magnituda) za HRP/HERC.**

Tablica 7: Prosječna unutar-prozorska korelacija težine i karakteristike dionice (13 prozora).


Portfelj	$\text{corr}(w, \sigma_\varepsilon)$	$\text{corr}(w, \beta_{\text{CMA}})$	$\text{corr}(w, \beta_{\text{RMW}})$
minimalna varijanca	-0.04	+0.09	+0.02
nco_corr	-0.14	+0.17	+0.07
herc_corr	-0.19	+0.14	+0.08
hrp_corr_single	-0.33	+0.31	+0.15
hrp_corr_ward	-0.44	+0.33	+0.16

Izvor: outputs/tables/10_weight_characteristic_corr.csv

Nagib je postojan kroz testne godine (slika 4): NCO i min-var ostaju na vrhu, HRP/HERC u sredini, $1/N$ i faktorski neutralan pri dnu, kroz sve režime (uzlet kvalitete, šok pandemije, kamatni ciklus 2022.--2023.).



Slika 3: Korelacija težina s rezidualnom volatilnošću i faktorskim betama po alokatoru: inverzno-varijančni mehanizam vidljiv je kao negativna veza s σ_ε i pozitivna s β_{CMA} .



Slika 4: Koncentracija stila po testnoj godini. Poredak je postojan kroz režime.

Faza 3: Prostor hijerarhije — neutralizira li faktorski prostor nagib? (H2)

Mijenjamo *samo* ulaz u hijerarhiju (korelacijsko $\rightarrow$ faktorsko stablo), uz konstantnu Wardovu vezu, Σ , univerzum i $w_{\max}$. Parne razlike faktorski – korelacijski po alokatoru (tablica 8) pokazuju da **faktorski prostor ne neutralizira nagib**: interval razlike koncentracije stila obuhvaća nulu za sva tri alokatora ($p \geq 0.43$). Volatilnost se ne pogoršava značajno ni za jedan alokator.

Tablica 8: Parne razlike (faktorski – korelacijski prostor) po alokatoru; HRP baza = `hrp_corr_ward` (K1).

Alokator	metrika	Δ	95 % CI	p
HRP	konc. stila	+0.012	[−0.02, 0.05]	0.426
HERC	konc. stila	+0.088	[−0.54, 0.24]	0.914
NCO	konc. stila	−0.061	[−0.15, 0.11]	0.528
HRP	god. vol.	+0.0003	[−0.001, 0.001]	0.542
HERC	god. vol.	+0.009	[−0.004, 0.022]	0.172
NCO	god. vol.	+0.001	[−0.004, 0.006]	0.648

Izvor: `outputs/tables/11_paired_diffs_space.csv`

Obećani dobitci se ne materijaliziraju pri $K = 10$. H2 je predviđala mjerljive dobitke u stabilnosti i obrtaju. Mjereni ARI između uzastopnih prozora *lošiji* je za faktorski prostor (0.25) nego za korelacijski (0.29); obrtaj je usporediv (HRP 0.25 vs 0.25, HERC 0.60 vs 0.59, NCO 0.56 vs 0.60). Bootstrap stabilnost pripadnosti tek je marginalno viša za faktorske klastere (Jaccard 0.488 vs 0.485). Jedina *konkretna* prednost faktorskog prostora jest **parsimonija**: hijerarhija na $6N$ beta umjesto na $N(N - 1)/2$ korelacija — pri $N \approx 411$ to je redukcija od $\sim 34\times$ u broju parametara. Koncentracija stila robusna je kroz K (NCO 0.74–0.88, HERC 0.56–0.66 kroz $K \in \{2, 10, 20\}$ i k-means; tablica 9), pa nagib opstaje i pri vlastito-optimalnom K . **Zaključak H2: „ne neutralizira” potvrđeno; „mjerljivi dobitci” ne ostvaruju se pri $K = 10$ — jedina prednost je dimenzijska parsimonija.**

Tablica 9: H2 popratne mjere: stabilnost, obrtaj i robusnost koncentracije stila kroz K .

Mjera	korelacijski	faktorski
srednji ARI (uzastopni prozori)	0.29	0.25
Jaccard stabilnost (bootstrap)	0.485	0.488
obrtaj HRP / HERC / NCO	0.25 / 0.60 / 0.56	0.25 / 0.59 / 0.60
konc. stila NCO ($K \in \{2, 10, 20\}$)	0.74–0.88 (robustno)	

Izvor: `outputs/tables/11_ari_stability.csv`, `11_turnover_by_space.csv`, `11_k_robustness.csv`, `02_cluster_stability.csv`

Faza 4: Mehanizam i lijek — overlay ograničenje beta (H3)

Budući da ni prostor hijerarhije ne uklanja nagib, primjenjujemo izravno ograničenje $|w^\top \beta_f| \leq \varepsilon$ kao QP overlay na hijerarhijske težine. Svih 24 varijanti izvedivo je u svih 13 prozora. Parne razlike overlay($\varepsilon=0$) – baza (tablica 10) pokazuju da overlay **značajno smanjuje koncentraciju stila u 5 od 6 alokator×prostor kombinacija** (jedino `herc_corr` graničan, $p = 0.066$), uz zanemariv ili neznačajan trošak u volatilnosti.

2×2 faktorijal. Konsolidirana tablica (tablica 11) prosjeka HRP/HERC/NCO razdvaja dva izvora variranja. *Prostor* jedva pomiče koncentraciju stila (korelacijski 0.647 naspram faktorski

Tablica 10: Parne razlike overlay ($\varepsilon=0$) – hijerarhijska baza; koncentracija stila i godišnja volatilnost (1000 bootstrap uzoraka).

Alokator	prostor	Δ konc. stila			Δ god. vol.	
		Δ	95 % CI	p	Δ	p
HRP	korel.	-0.118	$[-0.20, -0.07]$	0.012	+0.003	0.016
HERC	korel.	-0.187	$[-0.40, 0.02]$	0.066	+0.002	0.526
NCO	korel.	-0.330	$[-0.50, -0.14]$	0.002	+0.005	0.072
HRP	fakt.	-0.115	$[-0.21, -0.06]$	0.008	+0.003	0.016
HERC	fakt.	-0.116	$[-0.20, -0.03]$	0.006	-0.001	0.280
NCO	fakt.	-0.221	$[-0.46, -0.07]$	0.000	+0.006	0.040

Izvor: outputs/tables/12_h3 Paired diffs.csv


0.660 u baznom retku), dok *overlay* ($\varepsilon=0$) snižava srednju koncentraciju u oba prostora (korelacijski $0.647 \rightarrow 0.435$; faktorski $0.660 \rightarrow 0.509$) uz zanemarivu promjenu volatilnosti. Glavni efekt pripada mehanizmu ograničenja, ne prostoru hijerarhije.

Tablica 11: 2×2 faktorijal {prostor}×{overlay $\varepsilon=0$ }; srednje vrijednosti preko HRP/HERC/NCO.

Prostor	Overlay	sr. konc. stila	sr. god. vol
korelacijski	baza	0.647	13.4 %
korelacijski	overlay	0.435	13.7 %
faktorski	baza	0.660	13.8 %
faktorski	overlay	0.509	14.0 %

Izvor: outputs/tables/13_factorial_2x2.csv

Granica stil--volatilnost. Na granici koncentracija stila naspram ostvarene volatilnosti (slika 5) overlay točke dominiraju nisko-stilski dio fronte: nijedna bazna hijerarhijska varijanta nije Pareto-optimalna ondje gdje overlay smanjuje stil bez porasta volatilnosti. Nalaz je robustan na normu projekcije (Σ naspram euklidske: Δ koncentracije stila -0.011 do -0.027). **Zaključak H3: podržana.**



Slika 5: Koncentracija stila naspram ostvarene godišnje volatilnosti za svih 37 varijanti završne usporedbe; Paretova fronta istaknuta. Overlay varijante zauzimaju nisko-stilski dio fronte.

Što statistika rizika *ne* tvrdi. Model Confidence Set na ostvarenoj varijanci (gubitak $l_t = (r_t - \bar{r})^2$, $\alpha = 0.10$) zadržava 26/37 varijanti — cijelu nisko-volatilnu skupinu (sve NCO, faktorski neutralne, min-var, HRP s overlayem), dok HERC i $1/N$ ispadaju ($p = 0.032$); svih 156 mjeseci raspoloživo je svim varijantama pa nijedna nije isključena pravilom presjeka. MCS mjeri ostvarenu varijancu, ne stil. Deflated Sharpe Ratio (za 37 isprobanih varijanti) kreće se 0.55–0.73 i **nijedna varijanta ne prelazi prag 0.95**: riziku prilagođena prednost nije razlučiva od sreće nakon korekcije za višestruko isprobavanje (tablica 12). Studija tvrdi nešto o *stilu*, ne o nadmašivanju u prinosu.

Tablica 12: Statistika rizika: MCS članstvo (bruto) i raspon DSR-a.

Mjera	vrijednost
varijanti u MCS-u @ $\alpha=0.10$ (od 37)	26
isključeni pravilom presjeka ($> 20\%$ manjka)	0
najjače izbačeni (<code>equal_weight</code> , <code>herc_factor</code>)	$p = 0.032$
raspon DSR (bruto)	0.55--0.73
varijanti s $DSR \geq 0.95$	0

Izvor: outputs/tables/12_mcs_final.csv, 12_dsr.csv

Stari projekt kao referenca i motivacija

Prethodna faza (dijagnoza min-vara, neuspjeh grupnih ograničenja, izravna neutralnost) ugnježđuje se kao benchmark obitelj, ne baca se. Na novom point-in-time univerzumu replicira se njezin ključni nalaz: izravno linearno ograničenje na bete (`factor_neutral`) smanjuje koncentraciju stila minimalne varijance s 0.78 na 0.53 (-32%) uz neznačajan trošak u volatilnosti — blok-bootstrap razlika -0.251 , 95 % CI $[-0.44, -0.05]$, $p = 0.024$ za stil naspram $p = 0.066$ za volatilnost (tablica 13). Time stari rezultat motivira overlay iz Faze 4: mehanizam koji je radio na min-varu radi i kad se primijeni na hijerarhijske težine. Grupno ograničeni benchmarki (po sektoru / korelacijskom / faktorskom klasteru) i hibridna obitelj uklonjeni su iz novih panela jer na point-in-time S&P 500 univerzumu uvjet uloživosti $K \times \text{group_cap} \geq 1$ ne dopušta silueta-optimalan K ; ostaju u kodu kao legacy.

Tablica 13: Stari projekt na novom univerzumu: izravna faktorska neutralnost naspram minimalne varijance (blok-bootstrap razlike).

Usporedba ($\varepsilon=0$)	Δ	95 % CI	p
konc. stila (<code>factor_neutral</code> – min-var)	-0.251	$[-0.44, -0.05]$	0.024
god. vol. (<code>factor_neutral</code> – min-var)	+0.004	$[-0.0002, 0.008]$	0.066

Izvor: outputs/tables/05_bootstrap_ci_extended.csv, 05_risk_summary_all.csv

Zaključak

Gdje nastaje stilski rizik? U *mehanizmu*, ne u prostoru. Inverzno-varijančna jezgra koju dijele sva tri hijerarhijska alokatora uvlači RMW/CMA nagib (težina raste s padom rezidualne volatilnosti i porastom CMA-izloženosti). NCO ga nasljeđuje u punoj magnitudi (koncentracija stila $0.80 \approx \text{min-var}$), HRP i HERC u mehanizmu ali raspršeno (na razinu $1/N$).

Prostor hijerarhije nije lijek. Zamjena korelacijskog stabla faktorskim, uz konstantnu vezu, ne pomiče koncentraciju stila (razlika obuhvaća nulu za sva tri alokatora), a obećani dobitak u stabilnosti klastera ne ostvaruje se pri $K = 10$. Faktorski prostor donosi samo dimenzijsku parsimoniju ($\sim 34\times$ manje parametara).

Lijek je izravno ograničenje na bete. Overlay $|w^\top \beta_f| \leq \varepsilon$ na hijerarhijske težine značajno smanjuje koncentraciju stila (5/6 varijanti) uz zanemariv trošak u volatilitnosti i dominira na granici stil--volatilitnost; 2×2 faktorijal pripisuje glavni efekt mehanizmu ograničenja, ne prostoru. Statistika rizika (MCS, DSR) potvrđuje da je tvrdnja o stilu, ne o nadmašivanju u prinosu.

Glavna ograničenja.

- **Pokrivenost delistanih.** U point-in-time okviru pristranost je *nedostajuće članstvo*: jezgra od 321 delistanog imena bez Yahoo povijesti izostavljena je presjekom, a udio članova $s \geq 60$ mj. raste s 54.75 % na 95.63 % (tablica 1) — zato je backtest podrezan na 2013.--2025.
- **Šum beta.** Bete su procijenjene iz 60 mjesečnih opažanja, dovoljno malo da unesu šum; one ulaze samo u izgradnju hijerarhije, nikad u procjenu rizika.
- **Jednostavan model troškova.** Trošak je linearan (10 bps) i samo na refit obrtaj, uz fiksne težine unutar testne godine.
- **Nametanje $w_{\max}$.** Ograničenje pojedinačne pozicije provodi se iterativnim odsijecanjem na $w_{\max} = 0.05$ s renormalizacijom. Cap pritišće zamjetno samo kod NCO (prosječni udio težine na capu 0.07 u korelacijskom, 0.13 u faktorskom prostoru; ostali hijerarhijski ≈ 0 , min-var 0.09); kod NCO je dakle dijelom i ograničenje, a ne samo alokator, koje oblikuje težine.
- **Jedna klasa imovine.** Prinosi US large-cap dionica ostaju ~ 0.97 korelirani neovisno o capu i K ; snaga studije dolazi iz dispergije koncentracije stila (0.53–0.80), ne iz dekorelacije prinosa.

Robusnost i arhivirana proširenja. Kao dodatak robusnosti, faktorski prostor ponovno je klasteriran partijskim, vjerojatnosnim i gustoćnim metodama uz indekse interne validacije (notebook 07): struktura je otporna na izbor algoritma, a interni indeksi potvrđuju da je K u faktorskom prostoru slabo određen (silueta monotono pada), čime se opravdava domenski odabir $K = 10$. Nadzirano proširenje (predviđanje pada stablima i ansamblima; notebook 08, arhivirano) dalo je negativan rezultat: oznaka klastera ne dodaje prediktivnu vrijednost povrh samih beta, pa klaster ostaje izvrstan opisni, ali ne i prediktivni objekt.

Literatura

- [1] Bailey, D. H., & López de Prado, M. (2014). The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality. *Journal of Portfolio Management*, 40(5), 94–107.
- [2] Fama, E. F., & French, K. R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22.
- [3] Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The Model Confidence Set. *Econometrica*, 79(2), 453–497.
- [4] Ledoit, O., & Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.
- [5] López de Prado, M. (2016). Building Diversified Portfolios that Outperform Out of Sample. *Journal of Portfolio Management*, 42(4), 59–69.
- [6] López de Prado, M. (2019). *Machine Learning for Asset Managers*. Cambridge University Press (Nested Clustered Optimization).
- [7] Novy-Marx, R. (2014). Understanding Defensive Equity. *NBER Working Paper* No. 20591.

- [8] Raffinot, T. (2018). The Hierarchical Equal Risk Contribution Portfolio. *SSRN* 3237540.
- [9] Scherer, B. (2011). A note on the returns to minimum variance investing. *Journal of Empirical Finance*, 18(4), 652--660.