

Skriveni stilski rizik u portfeljima minimalne varijance

Dijagnoza faktorskim klasteriranjem na indeksu Russell 1000 (2005.--2025.)

Marin Meštrović

Dubinska analiza podataka i otkrivanje znanja u podatcima — PMF, Sveučilište u Zagrebu

Lipanj 2026.

Sažetak

Portfelji minimalne varijance isključivo s dugim pozicijama uobičajeno se promatraju kao „neutralna” referenca: po konstrukciji minimiziraju varijancu bez izričitoga stava o prinosima. Ovaj projekt pokazuje da takvi portfelji na indeksu Russell 1000 nose *skriven i postojan* nagib prema Fama--French stilskim faktorima profitabilnosti (RMW) i ulaganja (CMA), te da taj nagib ostaje skriven i sektorskoj i korelacijskoj diverzifikaciji. Dijagnozu gradimo klasteriranjem dionica u prostoru faktorske izloženosti — metodom otkrivanja znanja koja se obrađuje na kolegiju. Klasteriranje ispravno *lokalizira* problem, no intuitivni ispravak — ograničenje težine po klasteru — pokazuje se neuspješnim. Djelotvoran je ispravak izravno linearno ograničenje na faktorske bete portfelja, koje ostvarenu koncentraciju stila smanjuje za 31 % uz zanemariv trošak u volatilnosti ($p \approx 0.002$).

1 Ciljevi

Hipoteza projekta jest da mehanička minimizacija rizika neprimjetno daje prednost određenom području faktorskoga prostora te tako gradi skrivenu stilsku izloženost. Postavljamo tri pitanja koja ujedno čine i trodijelnu strukturu rada:

1. **Otkriće.** Nose li portfelji minimalne varijance skriven stilski nagib i može li se on učiniti vidljivim klasteriranjem u prostoru faktora?
2. **Neuspjeli ispravak.** Ako klasteri ocrtavaju problem, ublažava li ga ograničavanje težine portfelja po klasteru?
3. **Djelotvoran ispravak.** Ako ne, koje ograničenje uistinu smanjuje stilski nagib bez žrtvovanja niske volatilnosti?


Metodološko je težište na klasteriranju kao alatu za *otkrivanje znanja*: ono nije tek opisni korak, nego okvir kroz koji tumačimo cijelu analizu i izvor hipoteze o ispravku. Uz glavni tijek analize, projekt sustavno obuhvaća metode kolegija — particijsko, vjerojatnosno i na gustoći utemeljeno klasteriranje, odabir broja klastera indeksima interne validacije te nadzirana stabla odlučivanja i ansamble.

2 Podatci

- **Univerzum.** Trenutačni sastav indeksa Russell 1000 (1.002 dionice s pripadajućim GICS sektorima). Pristranost preživljavanja priznajemo: rabi se trenutačno članstvo u indeksu.

- **Cijene.** Dnevne prilagođene zaključne cijene (Yahoo Finance, `yfinance`), agregirane na zadnji dan u mjesecu.
- **Faktori.** Fama–French petfaktorski mjesečni prinosi iz zbirke podataka Kennetha Frencha (MKT, SMB, HML, RMW, CMA).
- **Razdoblje.** Od siječnja 2005. do prosinca 2025. (21 godina). Prvih pet godina čini prvi prozor procjene, a testne godine teku od 2010. do 2025.

Univerzum raste s približno 600 dionica u prozoru 2009-12 na približno 880 u prozoru 2024-12, kako dionice s kasnijim IPO-om počinju ispunjavati uvjete (slika 1).



Slika 1: Pokrivenost univerzuma kroz klizne prozore procjene: broj dionica s najmanje 60 valjanih mjeseci i čistom petfaktorskom prilagodbom.

3 Metodologija

Značajke dionice. Za svaki par (*prozor*, *dionica*) procjenjujemo OLS petfaktorsku regresiju (metoda najmanjih kvadrata) na viškovima prinosa i bilježimo $(\alpha, \beta_{\text{MKT}}, \beta_{\text{SMB}}, \beta_{\text{HML}}, \beta_{\text{RMW}}, \beta_{\text{CMA}}, \sigma_\varepsilon, R^2)$. Prilagodbe koje krše granice kvalitete ($|\beta| \leq 5$, $\sigma_\varepsilon \leq 0.50$, $R^2 \geq 0.05$) izbacuju se iz toga prozora.

Klasteriranje. Glavni predmet istraživanja jesu *faktorski klasteri*: Wardova veza na euklidskoj udaljenosti nad šest standardiziranih značajki (z-vrijednosti) $(\beta_{\text{MKT}}, \beta_{\text{SMB}}, \beta_{\text{HML}}, \beta_{\text{RMW}}, \beta_{\text{CMA}}, \sigma_\varepsilon)$. Kao referentne podjele za usporedbu služe *korelacijski klasteri* (potpuna veza na udaljenosti $\sqrt{2(1-\rho)}$) i *GICS sektori*. Broj klastera $K = 7$ najveća je vrijednost po prosječnoj silueti koja zadovoljava dva uvjeta uloživosti: svaki klaster ima ≥ 4 dionice u svakom prozoru te $K \times \text{group_cap} \geq 1$ uz $\text{group_cap} = 0.15$.

Portfelji. Svi su portfelji isključivo s dugim pozicijama, u svakom prozoru potpuno uloženi, uz ograničenje pojedinačne pozicije $w_{\text{max}} = 0.02$:

1. jednake težine $1/N$;
2. minimalna varijanca bez grupnoga ograničenja;
3. minimalna varijanca uz $\sum w_i \leq 0.15$ unutar svakog GICS sektora;
4. isto grupno ograničenje na korelacijskim klasterima;
5. isto grupno ograničenje na faktorskim klasterima;
6. faktorski neutralna minimalna varijanca: $|w^\top \beta_f| \leq \varepsilon$ za $f \in \{\text{SMB}, \text{HML}, \text{RMW}, \text{CMA}\}$, uz $\varepsilon \in \{0.00, 0.05, 0.10, 0.15\}$.


Kovarijancu procjenjujemo Ledoit--Wolfom sažimanjem na mjesečnim prinosima iz prozora procjene, preračunatu na godišnju razinu množenjem s 12. Glavna mjera nagiba jest **koncentracija stila** $|\beta_{\text{SMB}}| + |\beta_{\text{HML}}| + |\beta_{\text{RMW}}| + |\beta_{\text{CMA}}|$.

Klizni unaprijedni postupak (*walk-forward*) i bootstrap. Prozor procjene obuhvaća 60 mjeseci unatrag, testni horizont 12 mjeseci, a ponovnu procjenu provodimo svakih 12 mjeseci $\rightarrow$ 16 disjunktih testnih godina (2010.--2025.). Za intervale pouzdanosti razlika među metrikama koristimo blok-bootstrap (pomični blokovi od 12 mjeseci, 1000 ponovnih uzoraka).


4 Čin I — Otkriće

4.1 Klasteriranje otkriva faktorsku strukturu univerzuma

Faktorsko klasteriranje dijeli univerzum na sedam stilski koherentnih skupina. Radar-grafovi centroida (slika 2) prikazuju njihove standardizirane faktorske profile, a UMAP-projekcija, obojena na tri načina (slika 3), otkriva ključan nalaz: faktorski klasteri dijele univerzum po granicama koje ne prepoznaju ni korelacijski klasteri ni GICS sektori.



Slika 2: Radar-grafovi centroida sedam faktorskih klastera (standardizirani faktorski profili). Svaki klaster odgovara prepoznatljivu stilu.



Slika 3: UMAP-projekcija prostora faktora, obojena po faktorskom klasteru, korelacijskom klasteru i GICS sektoru. Faktorska se geometrija ne podudara ni sa sektorima ni s korelacijskom strukturom.

Stabilnost klastera pri bootstrap-ponovnom uzorkovanju umjerena je: srednji Jaccardov indeks zajedničke pripadnosti iznosi 0.30 za faktorske naspram 0.26 za korelacijske klastere, dovoljno da potvrdi kako struktura nije slučajnost svojstvena uzorku.


4.2 Skriveni nagib: minimalna varijanca naginje profitabilnosti i niskom ulaganju

Petfaktorska atribucija prinosa na punom testnom uzorku otkriva nagib (tablica 1).

Tablica 1: Petfaktorska atribucija na punom uzorku (192 mjeseca).


Portfelj	β_{MKT}	β_{SMB}	β_{HML}	β_{RMW}	β_{CMA}	konc. stila
Jednake težine	1.11	0.49	+0.09	0.08	0.17	0.83
Minimalna varijanca	0.66	0.20	−0.12	+0.33	+0.34	0.98
+ ograničenje sektora	0.68	0.21	−0.14	+0.26	+0.36	0.97
+ ogr. korelacijskih klastera	0.71	0.20	−0.09	+0.31	+0.26	0.86

Minimalna varijanca pokazuje jasnu pozitivnu izloženost faktorima RMW (+0.33) i CMA (+0.34) — prepoznatljiv stil visoke profitabilnosti i niskoga ulaganja. Koncentracija stila iznosi 0.98, znatno iznad vrijednosti 0.83 portfelja jednakih težina. Sektorsko ograničenje smješteno je gotovo točno povrh neograničene minimalne varijance; korelacijsko ograničenje koncentraciju umjereno snižava (0.86), no blok-bootstrap interval obuhvaća nulu ($p \approx 0.99$), pa razlika nije razlučiva od šuma. Nagib je usto *postojan* kroz sve režime (slika 4): oporavak nakon globalne financijske krize, uzlet kvalitetnih dionica nakon 2014., šok pandemije COVID-19 te kamatni ciklus 2022.–2023.



Slika 4: Koncentracija stila po testnoj godini za pet izvornih portfelja. Nagib minimalne varijance postojan je kroz režime.

Radi zornosti, slika 5 prikazuje kako svaki portfelj raspoređuje težinu po sedam faktorskih klastera. Minimalna varijanca koncentrira približno 84 % težine u samo dva klastera — defenzivni klaster velikih dionica i klaster niskoga ulaganja — čiji je zajednički profil upravo RMW/CMA nagib koji je dijagnoza prepoznala.



Slika 5: Raspodjela težina po sedam faktorskih klastera po portfelju (prozor 2024-12).

5 Čin II — Ograničenje po klasteru i njegov neuspjeh

Intuitivan ispravak glasi: budući da klasteri ocrtavaju stilska područja, ograničavanje težine svakog klastera na 15 % trebalo bi prisiliti optimizator da se raširi cijelim faktorskim prostorom i razrijedi nagib. Rezultat je, međutim, negativan (tablica 2).

Tablica 2: Učinak ograničenja faktorskih klastera (puni uzorak).

Portfelj	β_{MKT}	β_{SMB}	β_{HML}	β_{RMW}	β_{CMA}	konc. stila
Minimalna varijanca	0.66	0.20	-0.12	+0.33	+0.34	0.98
+ ogr. faktorskih klastera	0.83	0.55	-0.19	-0.15	+0.58	1.47

Ograničenje jest neutraliziralo ciljani RMW nagib (+0.33 → -0.15), no težinu je premjestilo u

klasterne s jačom izloženošću faktorima SMB i CMA ($\beta_{\text{SMB}} : 0.20 \rightarrow 0.55$; $\beta_{\text{CMA}} : 0.34 \rightarrow 0.58$). Rezultat je portfelj s *većom* ukupnom koncentracijom stila (1.47) i za 5.8 postotnih bodova višom godišnjom volatilnošću (blok-bootstrap $p \approx 0.000$).

Zašto ispravak ne uspijeva. Strukturni je razlog što su Wardovi klasteri u prostoru faktora po konstrukciji zbijeni — svaki je koherentna stilska skupina s vlastitim nagibom. Ograničenje grupne težine nadzire *koliko* težine pripada svakoj skupini, ali ne i *smjer* njezine faktorske izloženosti. Ukupna izloženost portfelja težinski je prosjek tih nagiba, koji se ne moraju međusobno poništiti. Ključan je uvid sljedeći: klasteri ispravno prepoznaju *gdje* faktorska struktura leži (izvršna su dijagnostika), ali su pogrešan mehanizam za ograničavanje. Da bi se nagib doista smanjio, ograničenje mora djelovati izravno na faktorske bete.

6 Čin III — Djelotvoran ispravak: izravna faktorska neutralnost

Neuspjeh ograničenja po klasteru uputio je na pravo rješenje. Kvadratni program minimalne varijance proširujemo linearnim ograničenjem koje djeluje upravo na geometriji koju je klasteriranje otkrilo — na faktorskim betama portfelja:

$$|w^\top \beta_f| \leq \varepsilon, \quad f \in \{\text{SMB, HML, RMW, CMA}\}.$$

Pritom je β_f vektor faktorskih izloženosti dionica procijenjen na istom prozoru procjene. $\varepsilon = 0$ nameće strogu faktorsku neutralnost u trenutku procjene, dok pozitivan ε dopušta nadziran nagib. Ograničenje je linearno, funkcija cilja ostaje nepromijenjena, a program konveksan.


Tablica 3: Atribucija i ostvarena volatilnost faktorski neutralne obitelji (puni uzorak).

Portfelj	β_{MKT}	β_{SMB}	β_{HML}	β_{RMW}	β_{CMA}	konc. stila	god. vol.
Minimalna varijanca	0.66	+0.20	−0.12	+0.33	+0.34	0.98	12.0 %
faktorski neutralan, $\varepsilon=0.00$	0.69	+0.18	−0.03	+0.26	+0.20	0.67	12.1 %
faktorski neutralan, $\varepsilon=0.05$	0.68	+0.19	−0.06	+0.29	+0.22	0.76	12.0 %
faktorski neutralan, $\varepsilon=0.10$	0.67	+0.19	−0.07	+0.31	+0.24	0.81	12.0 %
faktorski neutralan, $\varepsilon=0.15$	0.67	+0.21	−0.11	+0.30	+0.31	0.93	12.0 %

Najstroža postavka $\varepsilon = 0$ smanjuje ostvarenu koncentraciju stila za 31 % ($0.98 \rightarrow 0.67$) uz zanemariv trošak u volatilnosti. Blok-bootstrap interval razlike koncentracije stila u odnosu na minimalnu varijancu u cijelosti je ispod nule (-0.31 ; 95 % CI $[-0.47, -0.09]$; $p = 0.002$), dok interval razlike volatilnosti obuhvaća nulu ($p = 0.59$). Upravo je to kompromis koji je dijagnoza tražila (slika 6).


Tablica 4: Blok-bootstrap intervali razlika u odnosu na `min_var` (1000 ponovnih uzoraka).

Usporedba	Δ konc. stila	95 % CI	p
faktorski neutralan $\varepsilon=0.00$	−0.308	$[-0.47, -0.09]$	0.002
faktorski neutralan $\varepsilon=0.05$	−0.225	$[-0.39, -0.06]$	0.004
faktorski neutralan $\varepsilon=0.10$	−0.171	$[-0.32, -0.03]$	0.006
faktorski neutralan $\varepsilon=0.15$	−0.054	$[-0.10, -0.01]$	0.020



Slika 6: Bootstrap-distribucija razlike koncentracije stila (faktorski neutralan $\varepsilon=0$ – min_var). Interval leži u cijelosti ispod nule.

Granica koncentracije stila naspram ostvarene volatilnosti (slika 7) smješta čistu faktorski neutralnu obitelj na efikasnu granicu: ona smanjuje nagib bez porasta volatilnosti, dok hibridni portfelji (klaster + neutralnost) i faktorsko-klasterski portfelj to plaćaju višom volatilnošću.




Slika 7: Koncentracija stila naspram ostvarene godišnje volatilnosti za sve obitelji portfelja. Faktorski neutralna obitelj zauzima efikasnu granicu.

7 Pokrivenost metoda kolegija

Dva dodatka čvršće povezuju projekt s metodama kolegija i podvrgavaju njegove odluke dodatnoj provjeri.

Algoritmi klasteriranja i odabir K (predavanja 9b/10). Prostor faktora ponovno smo klasterirali particijskim metodama (K-means, k-medoid), vjerojatnosnom metodom (mješavina Gaussovih distribucija, EM) te metodom utemeljenom na gustoći (DBSCAN), uz odabir K pomoću siluete, Calinski–Harabaszova i Davies–Bouldinova indeksa te Gap statistike (slika 8). Zaključci: (i) struktura je otporna na izbor algoritma — K-means daje u osnovi iste skupine kao Wardova metoda ($\text{ARI} \approx 0.45$); (ii) sva četiri indeksa interne validacije upućuju na *statistički* prirodan K između 3 i 5, pa je $K = 7$ ponajprije uvjet uloživosti, a ne optimum siluete — što dijelom objašnjava zašto je ispravak ograničenjem po klasteru imao tako malo strukture za isko-

ristiti; (iii) DBSCAN ne pronalazi prirodne praznine u gustoći ($ARI \approx 0$), čime se potvrđuje da su metode sa zadanim K ovdje pravi alat.



Slika 8: Indeksi za odabir broja klastera i Gap statistika za Wardovu metodu i K-means. Prirodan K nalazi se u rasponu 3--5.

Nadzirano proširenje — predviđanje pada (predavanja 3--4). Za svaku dionicu i testno razdoblje označavamo „visok pad” (gori od medijana u presjeku te godine) te ga predviđamo iz značajki prozora procjene — stabilima odlučivanja (entropija / Gini, dubina 3) i ansamblima (slučajna šuma, gradijentni boosting) — uz unakrsnu validaciju grupiranu po testnoj godini (GroupKFold).

Tablica 5: Unakrsna validacija predviđanja pada (najbolji model po skupu značajki).

Skup značajki	najbolji ROC-AUC	najbolja točnost
samo faktorske bete	0.69	0.64
+ GICS sektor	0.69	0.63
+ oznaka faktorskog klastera	0.68	0.64

Pad je umjereno predvidljiv ($AUC \approx 0.69$ naspram 0.5), no signalom dominiraju rezidualna volatilnost (idiosinkratski rizik) i tržišna beta, a ne stilski faktori. Dodavanje GICS sektora ili oznake klastera ne donosi poboljšanje u odnosu na same bete: klaster je izvrstan *opisni* objekt, ali ne i dodatna *prediktivna* značajka. Taj rezultat iznosimo onakvim kakav jest — opisna struktura ne služi ujedno i kao prediktor.

8 Zaključak

Otkriće. Portfelji minimalne varijance na indeksu Russell 1000 nose skriven i postojan nagib prema faktorima profitabilnosti (RMW) i ulaganja (CMA) — koncentraciju stila skrivenu sektorskoj i korelacijskoj diverzifikaciji, ali jasno ocrtanu klasteriranjem u prostoru faktora.

Ispravak. Dodavanje linearnih ograničenja $|w^\top \beta_f| \leq \varepsilon$ izravno u kvadratni program smanjuje ostvarenu koncentraciju stila za 31 % pri $\varepsilon = 0$, bez vidljiva troška u volatilnosti ($p \approx 0.002$).

Pouka. Struktura faktorskih klastera bila je ispravna dijagnostika — učinila je skriveni nagib vidljivim — ali pogrešan mehanizam ispravka: ograničavanje grupne težine ne cilja nijednu pojedinačnu betu. Djelotvoran ispravak postavlja ograničenje točno ondje gdje je klasteriranje pokazalo problem: na same faktorske bete.

Glavna ograničenja. (i) Pristranost preživljavanja — univerzum je trenutačni sastav indeksa Russell 1000, a ne indeks u stvarnoj povijesnoj točki. (ii) Bete su procijenjene iz 60 mjesečnih opažanja, dovoljno malo da unesu šum u procjenu. (iii) Transakcijski troškovi i obrtaj zanemareni su. (iv) Predviđanje prinosa nije cilj; brojevi kumulativnoga rasta nuspojava su, a ne rezultat. (v) Korelacijsko-klasterski portfelj i hibridi pri $\varepsilon \in \{0, 0.05\}$ agregirani su preko manjega broja testnih mjeseci (168/180 naspram 192) zbog neizvedivosti u najranijim prozorima.

Programski kod, podatci i sve slike: repozitorij projekta (`src/`, `notebooks/ 01--08`, `outputs/`). Detaljan narativni izvještaj: `reports/final_report.md`.