

# Skriveni faktorski rizik u portfeljima minimalne varijance

Analiza i korekcija hijerarhijskim klasteriranjem na indeksu Russell 1000 (2005.–2025.)

Marin Meštrović

Dubinska analiza podataka i otkrivanje znanja iz podataka  
PMF, Sveučilište u Zagrebu

Lipanj 2026.

## Sažetak

Portfelji minimalne varijance s long pozicijama uobičajeno se promatraju kao neutralna referenca: po konstrukciji minimiziraju varijancu. Ovaj projekt pokazuje da takvi portfelji nose skrivenu izloženost prema Fama–French faktorima profitabilnosti (RMW) i ulaganja (CMA), te da taj nagib ostaje skriven i sektorskoj i korelacijskoj diverzifikaciji. Dijagnozu radimo klasteriranjem dionica u prostoru faktorske izloženosti. Klasteriranje ispravno *lokalizira* problem, no intuitivni ispravak (ograničenje težine po klasteru) pokazuje se neuspješnim. Uspješan ispravak je izravno linearno ograničenje na faktorske bete portfelja, koje ostvarenu koncentraciju stila smanjuje za 31 % uz zanemariv trošak u volatilnosti ( $p \approx 0.002$ ).

# Sadržaj

|                                                       |    |
|-------------------------------------------------------|----|
| Ciljevi                                               | 3  |
| Podaci                                                | 3  |
| Metodologija                                          | 4  |
| I: Istraživanje                                       | 4  |
| II: Ograničenje po klasteru i neuspjeh                | 7  |
| III: Uspješan ispravak: izravna faktorska neutralnost | 7  |
| Metodološka proširenja i provjere                     | 9  |
| Zaključak                                             | 10 |

## Ciljevi

Hipoteza projekta jest da klasična minimizacija rizika daje prednost određenom području faktorskoga prostora te tako gradi skrivenu stilsku izloženost. Postavljamo tri pitanja:


1. **Istraživanje.** Nose li portfelji minimalne varijance skrivenu stilsku izloženost i može li se ona učiniti vidljivom klasteriranjem u prostoru faktora?
2. **Neuspješan ispravak.** Ako klasteri ocrtavaju problem, ublažava li ga ograničavanje težine portfelja po klasteru?
3. **Uspješan ispravak.** Ako ne, možemo li naći ograničenje koje zapravo smanjuje stilsku izloženost bez žrtvovanja niske volatilnosti?

Metodološki fokus je na klasteriranju kao alatu za otkrivanje znanja: ono nije tek opisni korak, nego okvir kroz koji tumačimo analizu i ideju hipoteze za ispravak. Uz glavni tijek analize, projekt sustavno obuhvaća metode obrađene u kolegiju (particijsko, vjerojatnosno i klasteriranje utemeljeno na gustoći, odabir broja klastera indeksima interne validacije te nadzirana stabla odlučivanja i ansamble).

## Podaci

- **Skup dionica.** Trenutni sastav indeksa Russell 1000 (1.002 dionice s pripadajućim GICS sektorima).
- **Cijene.** Dnevne prilagođene zaključne cijene (Yahoo Finance, `yfinance`), agregirane na zadnji dan u mjesecu.
- **Faktori.** Fama–French petfaktorski mjesečni prinosi iz zbirke podataka Kennetha Frencha (MKT, SMB, HML, RMW, CMA).
- **Razdoblje.** Od siječnja 2005. do prosinca 2025. (21 godina). Prvih pet godina čini prvi prozor procjene, a testne godine teku od 2010. do 2025.

Univerzum raste s približno 600 dionica u prozoru 2009-12 na približno 880 u prozoru 2024-12, kako dionice s kasnijim IPO-om počinju ispunjavati uvjete (slika 1).



**Slika 1:** Pokrivenost univerzuma kroz klizne prozore procjene: broj dionica s najmanje 60 valjanih mjeseci i čistom petfaktorskom prilagodbom.

## Metodologija

**Značajke dionice.** Za svaki par (prozor, dionica) procjenjujemo OLS petfaktorsku regresiju (metoda najmanjih kvadrata) na viškovima prinosa i bilježimo

$$(\alpha, \beta_{\text{MKT}}, \beta_{\text{SMB}}, \beta_{\text{HML}}, \beta_{\text{RMW}}, \beta_{\text{CMA}}, \sigma_\varepsilon, R^2).$$

Prilagodbe koje krše granice kvalitete ( $|\beta| \leq 5$ ,  $\sigma_\varepsilon \leq 0.50$ ,  $R^2 \geq 0.05$ ) izbacuju se iz toga prozora.

**Klasteriranje.** Glavni predmet istraživanja jesu faktorski klasteri: Wardova veza na euklidskoj udaljenosti nad šest standardiziranih značajki:

$$(\beta_{\text{MKT}}, \beta_{\text{SMB}}, \beta_{\text{HML}}, \beta_{\text{RMW}}, \beta_{\text{CMA}}, \sigma_\varepsilon).$$

Kao referentne podjele za usporedbu služe *korelacijski klasteri* (potpuna veza na udaljenosti  $\sqrt{2(1-\rho)}$ ) i *GICS sektori*. Broj klastera  $K = 7$  najveća je vrijednost po prosječnoj silueti koja zadovoljava dva uvjeta uloživosti: svaki klaster ima  $\geq 4$  dionice u svakom prozoru, a vrijedi i  $K \times \text{group\_cap} \geq 1$  uz  $\text{group\_cap} = 0.15$ .

**Portfelji.** Svi su portfelji isključivo s long pozicijama, u svakom prozoru potpuno uloženi, uz ograničenje pojedinačne pozicije  $w_{\text{max}} = 0.02$ :

1. jednake težine  $1/N$ ;
2. minimalna varijanca bez grupnoga ograničenja;
3. minimalna varijanca uz  $\sum w_i \leq 0.15$  unutar svakog GICS sektora;
4. isto grupno ograničenje na korelacijskim klasterima;
5. isto grupno ograničenje na faktorskim klasterima;
6. faktorski neutralna minimalna varijanca:  $|w^\top \beta_f| \leq \varepsilon$  za  $f \in \{\text{SMB}, \text{HML}, \text{RMW}, \text{CMA}\}$ , uz  $\varepsilon \in \{0.00, 0.05, 0.10, 0.15\}$ .

Kovarijancu procjenjujemo Ledoit–Wolfvim sažimanjem na mjesečnim prinosisima iz prozora procjene, preračunatu na godišnju razinu množenjem s 12. Glavna mjera izloženosti jest **koncentracija stila**  $|\beta_{\text{SMB}}| + |\beta_{\text{HML}}| + |\beta_{\text{RMW}}| + |\beta_{\text{CMA}}|$ .


**Klizni walk-forward postupak i bootstrap.** Prozor procjene obuhvaća 60 mjeseci unatrag, testni horizont 12 mjeseci, a ponovnu procjenu provodimo svakih 12 mjeseci  $\rightarrow$  16 disjunktnih testnih godina (2010.–2025.). Za intervale pouzdanosti razlika među metrikama koristimo blok-bootstrap (pomični blokovi od 12 mjeseci, 1000 ponovnih uzoraka).

## I: Istraživanje


### Klasteriranje otkriva faktorsku strukturu

Faktorsko klasteriranje dijeli skup dionica na sedam stilski koherentnih skupina. Radar-grafovi centroida (slika 2) prikazuju njihove standardizirane faktorske profile, a UMAP-projekcija, obojena na tri načina (slika 3), otkriva ključan nalaz: faktorski klasteri dijele univerzum po granicama koje ne prepoznaju ni korelacijski klasteri ni GICS sektori.

Stabilnost klastera pri bootstrap uzorkovanju umjerena je: srednji Jaccardov indeks zajedničke pripadnosti iznosi 0.30 za faktorske naspram 0.26 za korelacijske klastere, dovoljno da potvrdi kako struktura nije slučajnost svojstvena uzorku.



**Slika 2:** Radar-grafovi centroida sedam faktorskih klastera (standardizirani faktorski profili).



**Slika 3:** UMAP-projeksija prostora faktora, obojena po faktorskom klasteru, korelacijskom klasteru i GICS sektoru. Faktorska se geometrija ne podudara ni sa sektorima ni s korelacijskom strukturom.


## Skrivena izloženost: minimalna varijanca naginje profitabilnosti i niskom ulaganju

Petfaktorska atribucija prinosa na punom testnom uzorku otkriva izloženost (tablica 1).

**Tablica 1:** Petfaktorska atribucija na punom uzorku (192 mjeseca).


| Portfelj                      | $\beta_{\text{MKT}}$ | $\beta_{\text{SMB}}$ | $\beta_{\text{HML}}$ | $\beta_{\text{RMW}}$ | $\beta_{\text{CMA}}$ | konc. stila |
|-------------------------------|----------------------|----------------------|----------------------|----------------------|----------------------|-------------|
| Jednake težine                | 1.11                 | 0.49                 | +0.09                | 0.08                 | 0.17                 | 0.83        |
| Minimalna varijanca           | 0.66                 | 0.20                 | -0.12                | <b>+0.33</b>         | <b>+0.34</b>         | 0.98        |
| + ograničenje sektora         | 0.68                 | 0.21                 | -0.14                | +0.26                | +0.36                | 0.97        |
| + ogr. korelacijskih klastera | 0.71                 | 0.20                 | -0.09                | +0.31                | +0.26                | 0.86        |

Minimalna varijanca pokazuje jasnu pozitivnu izloženost faktorima RMW (+0.33) i CMA (+0.34) – prepoznatljiv stil visoke profitabilnosti i niskoga ulaganja. Koncentracija stila iznosi 0.98, znatno iznad vrijednosti 0.83 portfelja jednakih težina. Sektorsko ograničenje smješteno je gotovo točno povrh neograničene minimalne varijance; korelacijsko ograničenje koncentraciju umjereno snižava (0.86), no razlika nije razlučiva od šuma. Nagib je postojan kroz sve režime (slika 4): oporavak nakon globalne financijske krize, uzlet kvalitetnih dionica nakon 2014., šok pandemije COVID-19 te kamatni ciklus 2022.–2023.



**Slika 4:** Koncentracija stila po testnoj godini za pet izvornih portfelja. Nagib minimalne varijance postojan je kroz režime.

Slika 5 prikazuje kako svaki portfelj raspoređuje težinu po sedam faktorskih klastera. Minimalna varijanca koncentrira približno 84 % težine u samo dva klastera: defenzivni klaster velikih dionica i klaster niskoga ulaganja, čiji je zajednički profil upravo RMW/CMA nagib koji je dijagnoza prepoznala.



**Slika 5:** Raspodjela težina po sedam faktorskih klastera po portfelju (prozor 2024-12).

## II: Ograničenje po klasteru i neuspjeh

Intuitivan ispravak glasi: budući da klasteri ocrtavaju stilska područja, ograničavanje težine svakog klastera na 15 % trebalo bi prisiliti optimizator da se raširi cijelim faktorskim prostorom i razrijedi nagib. Rezultat je, međutim, negativan (tablica 2).

**Tablica 2:** Učinak ograničenja faktorskih klastera (puni uzorak).

| Portfelj                   | $\beta_{\text{MKT}}$ | $\beta_{\text{SMB}}$ | $\beta_{\text{HML}}$ | $\beta_{\text{RMW}}$ | $\beta_{\text{CMA}}$ | konc. stila |
|----------------------------|----------------------|----------------------|----------------------|----------------------|----------------------|-------------|
| Minimalna varijanca        | 0.66                 | 0.20                 | -0.12                | +0.33                | +0.34                | 0.98        |
| + ogr. faktorskih klastera | 0.83                 | 0.55                 | -0.19                | -0.15                | +0.58                | <b>1.47</b> |

Ograničenje jest neutraliziralo ciljani RMW nagib ( $+0.33 \rightarrow -0.15$ ), no težinu je premjestilo u klaster s jačom izloženosti faktorima SMB i CMA ( $\beta_{\text{SMB}} : 0.20 \rightarrow 0.55$ ;  $\beta_{\text{CMA}} : 0.34 \rightarrow 0.58$ ). Rezultat je portfelj s većom ukupnom koncentracijom stila (1.47) i za 5.8 postotnih bodova višom godišnjom volatilnošću (blok-bootstrap  $p \approx 0.000$ ).

**Zašto ispravak ne uspijeva.** Strukturni je razlog što su Wardovi klasteri u prostoru faktora po konstrukciji zbijeni – svaki je koherentna stilska skupina s vlastitim nagibom. Ograničenje grupne težine nadzire koliko težine pripada svakoj skupini, ali ne i smjer faktorske izloženosti. Ukupna izloženost portfelja težinski je prosjek tih nagiba, koji se ne moraju međusobno poništiti. Ključan je uvid sljedeći: klasteri ispravno prepoznaju gdje faktorska struktura leži (odlična dijagnostika), ali su pogrešan mehanizam za ograničavanje. Da bi se nagib doista smanjio, ograničenje mora djelovati izravno na faktorske bete.

## III: Uspješan ispravak: izravna faktorska neutralnost

Neuspješno ograničavanje po klasteru uputilo je na bolje rješenje. Kvadratni program minimalne varijance proširujemo linearnim ograničenjem koje djeluje upravo na geometriji koju je klasteriranje otkrilo, tj. na faktorskim betama portfelja:

$$|w^\top \beta_f| \leq \varepsilon, \quad f \in \{\text{SMB, HML, RMW, CMA}\}.$$

Pritom je  $\beta_f$  vektor faktorskih izloženosti dionica procijenjen na istom prozoru procjene.  $\varepsilon = 0$  nameće strogu faktorsku neutralnost u trenutku procjene, dok pozitivan  $\varepsilon$  dopušta nadziran nagib.

**Tablica 3:** Atribucija i ostvarena volatilnost faktorski neutralne familije (puni uzorak).


| Portfelj                                | $\beta_{\text{MKT}}$ | $\beta_{\text{SMB}}$ | $\beta_{\text{HML}}$ | $\beta_{\text{RMW}}$ | $\beta_{\text{CMA}}$ | konc. stila | god. vol. |
|-----------------------------------------|----------------------|----------------------|----------------------|----------------------|----------------------|-------------|-----------|
| Minimalna varijanca                     | 0.66                 | +0.20                | -0.12                | +0.33                | +0.34                | 0.98        | 12.0 %    |
| faktorski neutralan, $\varepsilon=0.00$ | 0.69                 | +0.18                | -0.03                | +0.26                | +0.20                | <b>0.67</b> | 12.1 %    |
| faktorski neutralan, $\varepsilon=0.05$ | 0.68                 | +0.19                | -0.06                | +0.29                | +0.22                | 0.76        | 12.0 %    |
| faktorski neutralan, $\varepsilon=0.10$ | 0.67                 | +0.19                | -0.07                | +0.31                | +0.24                | 0.81        | 12.0 %    |
| faktorski neutralan, $\varepsilon=0.15$ | 0.67                 | +0.21                | -0.11                | +0.30                | +0.31                | 0.93        | 12.0 %    |

Najstroža postavka  $\varepsilon = 0$  smanjuje ostvarenu koncentraciju stila za 31 % ( $0.98 \rightarrow 0.67$ ) uz zanemariv trošak u volatilnosti. Blok-bootstrap interval razlike koncentracije stila u odnosu na minimalnu varijancu u cijelosti je ispod nule ( $-0.31$ ; 95 % CI  $[-0.47, -0.09]$ ;  $p = 0.002$ ), dok interval razlike volatilnosti obuhvaća nulu ( $p = 0.59$ ). Upravo je to kompromis koji je dijagnoza tražila (slika 6).


Granica koncentracije stila naspram ostvarene volatilnosti (slika 7) smješta čistu faktorski neutralnu obitelj na efikasnu granicu: ona smanjuje izloženost bez porasta volatilnosti, dok hibridni portfelji to plaćaju višom volatilnošću.

**Tablica 4:** Blok-bootstrap intervali razlika u odnosu na `min_var` (1000 ponovnih uzoraka).

| Usporedba                              | $\Delta$ konc. stila | 95 % CI          | $p$          |
|----------------------------------------|----------------------|------------------|--------------|
| faktorski neutralan $\varepsilon=0.00$ | <b>-0.308</b>        | $[-0.47, -0.09]$ | <b>0.002</b> |
| faktorski neutralan $\varepsilon=0.05$ | -0.225               | $[-0.39, -0.06]$ | 0.004        |
| faktorski neutralan $\varepsilon=0.10$ | -0.171               | $[-0.32, -0.03]$ | 0.006        |
| faktorski neutralan $\varepsilon=0.15$ | -0.054               | $[-0.10, -0.01]$ | 0.020        |



**Slika 6:** Bootstrap-distribucija razlike koncentracije stila (faktorski neutralan  $\varepsilon=0$  – `min_var`). Interval leži u cijelosti ispod nule.




**Slika 7:** Koncentracija stila naspram ostvarene godišnje volatilnosti za sve familije portfelja. Faktorski neutralna familija zauzima efikasnu granicu.



## Metodološka proširenja i provjere

Dva dodatna pokusa provjeravaju robusnost odabranog klasteriranja i ispituju može li se ista faktorska reprezentacija koristiti i prediktivno.

**Algoritmi klasteriranja i odabir  $K$ .** Prostor faktora ponovno smo klasterirali particijskim metodama (K-means, k-medoid), vjerojatnosnom metodom (mješavina Gaussovih distribucija, EM) te metodom utemeljenom na gustoći (DBSCAN), uz odabir  $K$  pomoću siluete, Calinski–Harabaszova i Davies–Bouldinova indeksa te Gap statistike (slika 8). Zaključci: (i) struktura je otporna na izbor algoritma – K-means daje u osnovi iste skupine kao Wardova metoda (ARI  $\approx 0.45$ ); (ii) sva četiri indeksa interne validacije upućuju na *statistički* prirodan  $K$  između 3 i 5, pa je  $K = 7$  ponajprije uvjet uloživosti, a ne optimum siluete, što dijelom objašnjava zašto je ispravak ograničenjem po klasteru imao tako malo strukture za iskoristiti; (iii) DBSCAN ne pronalazi prirodne praznine u gustoći (ARI  $\approx 0$ ), čime se potvrđuje da su metode sa zadanim  $K$  ovdje pravi alat.



**Slika 8:** Indeksi za odabir broja klastera i Gap statistika za Wardovu metodu i K-means. Prirodan  $K$  nalazi se u rasponu 3–5.

**Nadzirano proširenje (predviđanje pada).** Za svaku dionicu i testno razdoblje označavamo „visok pad” (gori od medijana u presjeku te godine) te ga predviđamo iz značajki prozora procjene, stablima odlučivanja (entropija / Gini, dubina 3) i ansamblima (slučajna šuma, gradijentni boosting) – uz unakrsnu validaciju grupiranu po testnoj godini (GroupKFold).

**Tablica 5:** Unakrsna validacija predviđanja pada (najbolji model po skupu značajki).

| Skup značajki                | najbolji ROC-AUC | najbolja točnost |
|------------------------------|------------------|------------------|
| samo faktorske bete          | 0.69             | 0.64             |
| + GICS sektor                | 0.69             | 0.63             |
| + oznaka faktorskog klastera | 0.68             | 0.64             |

Pad je umjereno predvidljiv ( $AUC \approx 0.69$  naspram 0.5), no signalom dominiraju rezidualna volatilnost (idiosinkratski rizik) i tržišna beta, a ne stilski faktori. Dodavanje GICS sektora ili

oznake klastera ne donosi poboljšanje u odnosu na same bete: klaster je izvrstan *opisni* objekt, ali ne i dodatna *prediktivna* značajka.

## Zaključak

**Istraživanje.** Portfelji minimalne varijance na indeksu Russell 1000 nose skrivenu izloženost prema faktorima profitabilnosti (RMW) i ulaganja (CMA) – koncentraciju stila skrivenu sektorskoj i korelacijskoj diverzifikaciji, ali jasno ocrtanu klasteriranjem u prostoru faktora.

**Ispravak.** Dodavanje linearnih ograničenja  $|w^\top \beta_f| \leq \varepsilon$  izravno u kvadratni program smanjuje ostvarenu koncentraciju stila za 31 % pri  $\varepsilon = 0$ , bez vidljiva troška u volatilnosti ( $p \approx 0.002$ ).

**Sažetak.** Struktura faktorskih klastera bila je ispravna dijagnostika – učinila je skriveni nagib vidljivim, ali pogrešan mehanizam ispravka: ograničavanje grupne težine ne cilja nijednu pojedinačnu betu. Uspješan ispravak postavlja ograničenje točno ondje gdje je klasteriranje pokazalo problem: na faktorske bete.

**Glavna ograničenja.** (i) Pristranost preživljavanja – skup dionica je trenutačni sastav indeksa Russell 1000, a ne indeks u stvarnoj povijesnoj točki. (ii) Bete su procijenjene iz 60 mjesečnih opažanja, dovoljno malo da unesu šum u procjenu. (iii) Transakcijski troškovi su izostavljeni. (iv) Korelacijsko-klasterski portfelj i hibridi pri  $\varepsilon \in \{0, 0.05\}$  agregirani su preko manjega broja testnih mjeseci (168/180 naspram 192) zbog neizvedivosti u najranijim prozorima.